

以下是视频中三类“去AI味”方法的详细拆解，操作聚焦“简单可落地”

AkiroMusic

一、示意攻击：利用“文本改写”打破AI输出特征

核心原理

通过改变文本原始表述形式，破坏AI生成内容的固定概率分布（如句式、用词习惯），让检测系统无法匹配AI文本特征。该方法原本用于文本改写，后验证对AI生成内容同样有效。

具体操作（2步）

1. 多语言“出口转内销”改写

将AI生成的中文文本，先翻译为小语种（如日语、德语，避免英语等常见语种的翻译同质化），再将小语种译文翻译回中文；重复1-2轮，文本表述会与原始AI输出差异显著，且保留核心语义。

2. 多AI交叉改写+差异化提示词 - 不依赖单一AI工具，选择2-3个不同厂商的大模型（如DeepSeek、Claude、豆包等）；

对每个AI使用不同提示词（例：给AI1的提示词为“学术化改写，保留专业术语”，给AI2的提示词为“用科研人员对话风格改写，适当加入逻辑连接词”），最后整合改写结果，进一步稀释单一AI的输出特征。

二、对抗攻击：通过“局部调整”欺骗检测规则

核心原理

针对AI文本“句式趋同、缺乏灵动”的弱点，人工干预文本细节（用词、句式、表达风格），模拟人类写作的“随机性”，降低检测系统对“AI特征”的判定。

具体操作（4类简单动作）

1. 用词微调：对重复率高的AI常用词（如“综上所述”“由此可见”“不难发现”），替换为同义词或同类表达（例：“综上”→“结合前文分析”，“不难发现”→“从数据结果可直观观察到”）；

2. 句式改造：将AI偏好的“陈述句”改为多样化句式—— 长句拆短句（例：“AI生成文本因句式统一易被检测”→“AI生成文本有个明显特点：句式统一。这个特点让它很容易被检测出来”）；

- 加入问句/感叹句（例：“该结论需进一步验证” → “该结论真的可靠吗？还需要更多实验数据来验证！”）；
- 适当用倒装句（例：“这类情况在学术写作中较少见” → “在学术写作中，这类情况较少见”）；

3. **增删细节**：在段落中加入“人类化细节”，如补充具体案例的微小描述（例：“参考了XX文献” → “参考了XX文献中2023年的实验组数据，该数据与本研究样本特征高度匹配”），或删除AI冗余的“套话”（如无意义的过渡句“在当今学术界，XX问题备受关注”）；
4. **口语化适配**：若文本场景允许（如课程论文的讨论部分），加入轻度口语化表达（例：“这个现象挺有意思”“从实际操作来看，这种方法更实用”），但需注意保留学术严谨性，避免过度口语化。

三、提示词攻击：从“源头”改变AI输出风格

核心原理

大语言模型对提示词高度敏感，微调指令风格即可直接改变AI的输出特征——让AI生成的内容更贴近“人类写作习惯”，而非标准AI话术。

具体操作（1个核心技巧）

给AI的提示词“加风格约束”，避免使用笼统指令（如“写一段关于XX的分析”），而是加入人类写作的细节要求，例：

- 原始提示词：“写500字关于AI检测原理的学术分析”；
- 优化后提示词：“以科研新手的视角，写500字关于AI检测原理的分析，过程中加入1个自己的疑问（比如‘困惑度指标会不会受文本长度影响？’），用词不用太复杂，偶尔用短句断开逻辑”。
通过这种方式，AI输出会自带“人类思考痕迹”，减少“机器感”。

四、关键总结

所有“去AI味”方法的**核心逻辑**：通过“改写形式、调整细节、优化指令”，改变AI生成文本的固定概率分布，让检测系统无法精准匹配“AI特征”；但本质是“模拟人类写作”，而非“造假”——最终需回归学术本质，确保内容有实验支撑、逻辑严谨，AI仅作为辅助工具。